

이기찬

Applied AI Engineer — 연구를 작동하는 제품으로 옮기고, 감이 아니라 측정으로 고르는 엔지니어

010-6666-2824 | gichanlee@icloud.com | github.com/bookseal | bit-habit.com

요약

- 연구 → 제품 전환 — 항공법 RAG 를 45 개 설정 eval 하네스로 측정해 배포, 감사 채점 9/10 · 1 등.
- **Structured Output · Tool Calling** — 강제 tool_use+Pydantic 추출기. LangGraph 에이전트를 배포.
- **LLM/Agent observability** — Prometheus 로 k3s 14 개 서비스 관측. 상태 그래프·재시도로 "조용한 실패" 방지.
- **프로덕션 SWE** — 도메인 로직 분리 + 단위 테스트(quali-fit), Docker-CI/CD. Flask-FastAPI-LangChain-Anthropic SDK.

경력

한국경영분석연구원 (KIBA) | AI Technical Product Manager / Lead AI FDE 2026.05 – 현재

- **LLM 에이전트를 사내 실행 표준으로 내재화** — LLM 을 개발 프로세스에 이식해 이슈→PR→코드리뷰 자동화. Teams STT 를 NotebookLM 에 연동해 회의록 요약·검색 자동화.
- **연구·지침을 작동하는 워크플로우로 전환** — 정부 대가 산정 가이드 분석을 LLM 워크플로우로 재설계해 10 시간 → 2 시간.
- **프로덕션 레벨 설계·테스트·배포 (quali-fit)** — 사내 인력 추천 도구. **도메인 로직(scoring-validation)**을 UI-DB 에서 완전히 분리하고 단위 테스트로 고정 — 프론트를 FastAPI 로 갈아끼워도 재작성이 필요 없는 구조. Docker 이미지로 배포.

Bithabit | AI Architect / Infrastructure Owner (Founder) 2024.08 – 현재

- **LLM App Lab — 에이전트 실행·평가 실험실 (llm-app-lab.bit-habit.com)** — Flask + Anthropic SDK 애플을 **k3s scale-to-zero** 런처로 온디맨드 서빙(0→1, 유휴 시 자동 회수). 강제 tool_use+Pydantic 추출기, RAG, 파인튜닝 모듈을 브라우저에서 실행.
- **RAG 최적화 — 감이 아니라 측정으로** — 14 CFR 1,297 쪽. \$경계 청킹으로 coverage 0.86(고정 청킹 0.41). 그리드서치 후 "노이즈 범위면 더 째 쪽" 규칙으로 배포본 선정(토큰 38% ↓), 재랭킹으로 최악 질문 **15,482→2,256 토큰**. 더 잘 검색하는 agentic 루프는 비용 대비 이득이 없어 **폐기하고 single-shot 배포**.
- **BookToss — LangGraph 에이전트** — 공개 API 없는 도서관 25 곳을 웹 도구로 감싸 **Tool Calling** 으로 통합 검색. 실패·재시도를 상태 그래프로 처리(5 분→1 분). **Solar API 로 재구축** 후 강점·한계를 공개 피드백으로 정리.
- **관측·배포 자동화** — k3s 14 개 서비스 2 년 무중단. ArgoCD GitOps, Prometheus 관측. 헬스 대시보드·아키텍처 문서를 외부 공개(status.bit-habit.com · infra.bit-habit.com).

Concentrix Korea (Microsoft M365) | Technical Success Advisor 2025.08 – 2025.11

- **글로벌 기술지원 전 지표 팀 1 위 (20 명 중)** — 해결률 92.7%, 불만족 0%. 문제를 재현·진단하고 절차를 문서로 자산화.

기술 스택

- **AI & Agent**: LangGraph/LangChain, **Structured Output · Forced Tool Use · Pydantic**, RAG(\$청킹·재랭킹·토큰예산), **Eval 하네스**(coverage/recall/MRR), Anthropic SDK, MCP, Browser-use, LLM API(Solar·Claude·GPT)
- **Backend & Infra**: Python-Flask-FastAPI, k8s(k3s)·Docker·ArgoCD, **k8s scale-to-zero** 서빙, **Prometheus·Gatus**, CI/CD, AWS·OCI·Azure · C/C++·TS·Bash · NumPy·임베딩·벡터검색·PostgreSQL

학력 & 활동

- **École 42 Seoul** — CS (2022.10–2024.10). UNIX 시스템·네트워크·동시성을 **C 로 밑바닥부터 구현**(소켓 서버·스레드·Docker 인프라). 3 년간 동료 스터디 운영.
- **부경대학교 산업공학 학사 · Fast Campus × Upstage AI Lab 수료** (Solar, Document Parse)
- **기술 내재화·공유** — LLM App Lab(강의·코드 전체 공개), Cloud Architect's Playbook(wiki.bit-habit.com) 집필·공개